



Komparasi Algoritma Apriori, ECLAT dan FP-Growth dalam Menemukan Pola Pembelian pada Dataset Online Retail

Ananda Keissa Az Zahra (24031554051), Laili Nurrohmatul Fadhlila Z. (24031554093),
Eka Putri Maharani (24031554121), Ulfa Siti Nuraini, S.Stat., M.Stat.
Kelas 2024E

Program Studi Sains Data, Universitas Negeri Surabaya

Abstrak. Penelitian ini bertujuan untuk mengimplementasikan teknik Association Rule Mining dalam menemukan pola asosiasi produk pada dataset Online Retail serta membandingkan efisiensi algoritma Apriori, ECLAT, dan FP-Growth berdasarkan waktu eksekusi dan penggunaan memori. Tahapan penelitian meliputi preprocessing data, transformasi basket transaction, pencarian frequent itemset, dan pembentukan association rules menggunakan variasi minimum support 0,01; 0,02; dan 0,05. Hasil penelitian menunjukkan algoritma Apriori memiliki performa paling efisien pada dataset yang bersifat sparse dengan waktu eksekusi tercepat dan penggunaan memori paling sedikit. Pada minimum support 0,02 diperoleh 401 frequent itemset dan 218 association rules yang representatif untuk dianalisis. Pola asosiasi terkuat ditemukan pada produk dekorasi Natal Skandinavia dan koleksi Regency Teacup and Saucer dengan nilai confidence hingga 90,3% dan lift mencapai 27,197. Hasil penelitian menunjukkan bahwa association rules dapat dimanfaatkan untuk strategi cross-selling, produk bundling, rekomendasi otomatis, dan penempatan produk pada bisnis ritel.

Kata kunci: Association Rule Mining, Market Basket Analysis, Apriori, ECLAT, FP-Growth, Frequent Itemset, Association Rules, Online Retail

BAB 1 Pendahuluan

1.1 Latar Belakang

Perkembangan pesat teknologi digital dan transformasi ekosistem *e-commerce* telah memicu perubahan besar dalam produksi data transaksi harian. Setiap interaksi pelanggan, mulai dari penelusuran produk hingga penyelesaian pembayaran, terekam secara sistematis dan membentuk *Big Data*. Namun, permasalahan yang kerap dihadapi oleh industri *online retail* adalah ketidakmampuan dalam mengekstraksi nilai dan tumpukan data transaksi tersebut. Data seringkali hanya digunakan sebagai arsip pencatatan dan belum dioptimalkan sebagai landasan strategis untuk memahami perilaku pembelian pelanggan. Tanpa pemahaman yang mendalam mengenai pola keranjang belanja pelanggan, perusahaan berisiko merancang strategi promosi yang tidak tepat sasaran, mengalami *overstock* akibat ketidaktepatan sistem rekomendasi, serta menyia-nyiakan potensi peningkatan *Customer Lifetime Value* (CLV) yang seharusnya dapat diraih lewat taktik *cross-selling* dan *up-selling*. Oleh karena itu, diperlukan suatu pendekatan komputasional untuk menemukan hubungan tersembunyi antar produk dalam *Big Data*.

Penelitian ini mengimplementasikan teknik *Data Mining*, secara spesifik menggunakan metode *Association Rule Mining* atau yang sering diaplikasikan sebagai *Market Basket Analysis* (MBA). Metode ini dipilih karena sangat efektif dalam mengidentifikasi probabilitas kemunculan produk secara bersamaan dalam satu transaksi yang menghasilkan *association rule* sehingga dapat langsung diinterpretasikan menjadi rekomendasi bisnis. Dalam proses pembentukan *association rule*, tahapan paling

krusial dan memakan beban komputasi terbesar adalah *Frequent Itemset Mining*. Penelitian ini tidak hanya mengaplikasikan satu algoritma, melainkan melakukan studi komparatif terhadap tiga algoritma dasar yakni Apriori, *Equivalence Class Transformation* (Eclat) dan *Frequent Pattern Growth* (FP-Growth).

Pemilihan untuk membandingkan ketiga metode ini didasarkan pada karakteristik data *Online Retail* yang memiliki dimensi baris ratusan ribu transaksi. Algoritma Apriori, memiliki kelemahan signifikan dalam hal efisiensi karena melakukan pemindaian basis data berulang kali untuk menghasilkan kandidat (Pratama et al., 2023). Hal ini menyebabkan penggunaan memori yang sangat tinggi. Sebaliknya, metode FP-Growth dinilai lebih unggul dan efektif untuk dataset berukuran besar karena menggunakan struktur data *Tree* (Pohon) yang menghilangkan kebutuhan pembuatan kandidat *itemset*, sehingga secara drastis menekan waktu eksekusi (Rahman & Kumar, 2024). Di sisi lain, algoritma Eclat menawarkan paradigma yang berbeda melalui pendekatan representasi data vertikal, yang terbukti secara komputasional sangat cepat untuk menemukan persimpangan (*intersection*) antar ID transaksi tanpa memindai seluruh *database* secara horizontal (Chen & Li, 2022).

Penelitian ini dilakukan dengan membandingkan kecepatan waktu eksekusi dan penggunaan memori dari masing-masing algoritma pada beberapa nilai *minimum support*. Tujuannya adalah untuk melihat secara langsung algoritma mana yang paling efisien, sekaligus menemukan pola kombinasi produk yang bisa dijadikan acuan untuk strategi *bundling* penjualan.

1.2 Rumusan Masalah

1. Bagaimana mengimplementasikan teknik *Association Rule Mining* untuk menemukan pola asosiasi produk pada dataset *Online Retail*?
2. Aturan asosiasi (*association rules*) seperti apa yang dapat direkomendasikan untuk mendukung strategi *cross-selling* pada bisnis ritel tersebut?
3. Bagaimana perbandingan tingkat efisiensi algoritma Apriori, FP-Growth, dan Eclat berdasarkan parameter waktu eksekusi dan konsumsi memori pada pemrosesan dataset transaksi berskala besar?

1.3 Tujuan Penelitian

1. Menerapkan tahapan *knowledge discovery in databases* (KDD) untuk menghasilkan pola hubungan antar barang dari dataset *Online Retail*.
2. Menemukan kombinasi item produk dengan nilai *confidence* dan *lift* tertinggi sebagai rekomendasi strategi pemasaran berbasis keranjang belanja pelanggan.
3. Melakukan evaluasi kinerja secara komparatif antara algoritma Apriori, FP-Growth, dan Eclat untuk menentukan metode *frequent itemset mining* yang paling optimal dan efisien dalam studi kasus ini.

BAB 2 Metodologi Penelitian

2.1 Dataset Penelitian

Dataset yang digunakan dalam penelitian ini adalah *Online Retail* Dataset yang diperoleh dari Kaggle melalui tautan berikut:

<https://www.kaggle.com/datasets/tunguz/online-retail>. Dataset ini berisi data transaksi penjualan sebuah perusahaan retail online yang menjual berbagai produk kebutuhan rumah tangga dan souvenir kepada pelanggan dari berbagai negara. Dataset terdiri dari sekitar 541.909 data transaksi dengan 8 atribut utama yaitu *invoiceNo*, *StockCode*, *description*, *Quantity*, *InvoiceData*, *UnitPrice*, *CustomerID*, dan *Country*. Data transaksi dataset ini dari periode 1 Desember 2010 sampai 9 desember 2011.

2.2 Variabel Penelitian

Variabel yang digunakan merupakan atribut yang relevan untuk proses *association rule mining*. Variabel ini dipilih karena mampu merepresentasikan transaksi pembelian pelanggan dan hubungan antar produk yang dibeli.

Tabel 1. Variabel Penelitian

Variabel	Deskripsi
InvoiceNo	Nomor unik transaksi pembelian
StockCode	Kode unik produk
Description	Nama produk
Quantity	Jumlah produk yang dibeli
InvoiceDate	Waktu transaksi
UnitPrice	Harga produk per unit
Country	Negara pelanggan

Dalam penelitian ini atribut paling utama yang digunakan adalah *InvoiceNo* dan *Description*. Atribut *InvoiceNo* digunakan untuk mengelompokkan item dalam satu transaksi, sedangkan *Description* digunakan sebagai nama item produk dalam proses pembentukan *basket transaction*.

2.3 Tahapan Penelitian

Penelitian ini menggunakan pendekatan *Knowledge Discovery in Databases* (KDD) yang terdiri atas beberapa tahapan utama yaitu data *selection*, *preprocessing*, *transformation*, *data mining*, dan *evaluation*.

2.3.1 Data Selection

Tahap data selection dilakukan dengan memilih atribut yang relevan dari dataset *Online Retail*. Atribut yang digunakan meliputi *InvoiceNo*, *Description*, *Quantity*, *UnitPrice*, dan *Country* karena berkaitan dengan proses transaksi pembelian. Selain itu, penelitian ini hanya menggunakan data transaksi dari negara United Kingdom (UK) yang berjumlah 495.478 dari keseluruhan data sekitar 541.909 data atau sekitar 91,4% dari keseluruhan dataset. Hal ini dilakukan karena sebagian besar transaksi pada dataset berasal dari negara tersebut sehingga diharapkan mampu merepresentasikan pola pembelian yang lebih konsisten dan mengurangi kompleksitas data.

2.3.2 Data Preprocessing

Tahap dilakukan untuk membersihkan data agar siap digunakan pada proses mining. Preprocessing bertujuan untuk meningkatkan kualitas data dan mengurangi noise yang dapat mempengaruhi hasil mining.

Proses preprocessing meliputi:

- Menghapus Data yang Memiliki *Missing Value*
Penghapusan missing value dilakukan terutama pada atribut Description karena atribut tersebut digunakan sebagai representasi item produk dalam transaksi. Data tanpa informasi produk dapat menyebabkan kesalahan dalam pembentukan basket transaction dan frequent itemset.
- Menghapus Transaksi Pembatalan
Transaksi pembatalan diidentifikasi melalui *InvoiceNo* yang diawali huruf "C". data tersebut dihapus karena tidak merepresentasikan transaksi pembelian aktual pelanggan sehingga dapat mempengaruhi pembentukan association rule.
- Menghapus Nilai *Quantity* Bernilai Nol atau Negatif
Nilai *Quantity* yang bernilai nol atau negatif menunjukkan adanya pengembalian barang, pembatalan sebagian transaksi, atau kesalahan input data. Penghapusan data tersebut dilakukan untuk menjaga konsistensi transaksi yang digunakan dalam proses mining.
- Menghapus data duplikat
Data duplikat dihapus untuk menghindari perhitungan frekuensi itemset secara berulang yang dapat menyebabkan bias pada hasil association rule mining.
- Menyaring data yang tidak relevan
Penelitian hanya menggunakan transaksi dari negara United Kingdom karena negara tersebut memiliki jumlah transaksi terbesar pada dataset Online Retail sehingga lebih representatif dalam menggambarkan pola pembelian konsumen. Selain itu, atribut yang tidak relevan terhadap proses association rule mining seperti CustomerID dihapus karena penelitian difokuskan pada hubungan antar produk dalam transaksi, bukan perilaku individu pelanggan.
- Melakukan Normalisasi Nama Produk
Normalisasi dilakukan pada atribut Description dengan menghapus spasi yang tidak diperlukan dan menyamakan format huruf menjadi kapital. Proses ini bertujuan untuk menghindari perbedaan penulisan pada produk yang sama sehingga tidak dianggap sebagai item berbeda oleh sistem.

2.3.3 Data transformation

Tahap ini data transaksi akan diubah ke bentuk *basket transaction* agar dapat diproses oleh algoritma *association rule mining*. Data kemudian ditransformasikan menjadi format biner, dimana setiap produk direpresentasikan dengan nilai 1 jika produk dibeli dan nilai 0 jika produk tidak dibeli. Transformasi ini diperlukan untuk mempermudah proses pencarian *frequent itemset*.

2.3.4 Frequent Itemset Mining

Tahap ini dilakukan untuk menemukan kombinasi item yang sering muncul dalam



transaksi pelanggan. Penelitian ini menggunakan tiga algoritma yaitu Apriori, ECLAT, dan FP-Growth. Setiap algoritma akan menggunakan nilai minimum support tertentu untuk menghasilkan frequent itemset yang memenuhi batas frekuensi kemunculan.

2.3.5 Association Rule Mining

Frequent itemset yang diperoleh kemudian digunakan untuk membentuk association rule. Aturan asosiasi digunakan untuk mengetahui hubungan antar produk berdasarkan tingkat keterkaitan dalam transaksi pembelian. Parameter yang digunakan dalam pembentukan association rule adalah Support, Confidence, Lift.

2.3.6 Evaluation

Tahap evaluation dilakukan untuk membandingkan performa algoritma Apriori, ECLAT, dan FP-Growth. Evaluasi dilakukan berdasarkan waktu eksekusi algoritma, jumlah frequent itemset yang dihasilkan, jumlah association rule yang terbentuk, efisiensi proses mining, hasil evaluasi digunakan untuk menentukan algoritma yang paling optimal dalam menganalisis dataset Online Retail.

2.4 Algoritma yang Digunakan

2.4.1 Apriori

Apriori merupakan algoritma association rule mining yang digunakan untuk menemukan frequent itemset berdasarkan nilai *minimum support* dan *confidence*. Algoritma ini bekerja dengan membentuk kandidat itemset secara bertahap dan melakukan proses *scanning database* secara berulang untuk menemukan kombinasi item yang sering muncul dalam transaksi (Xie, 2021). Kelebihan algoritma Apriori adalah mudah dipahami dan sering digunakan dalam penelitian market basket analysis. Namun, algoritma ini memiliki kelemahan pada efisiensi komputasi karena menghasilkan kandidat itemset dalam jumlah besar serta membutuhkan scanning database berulang kali (Wardani, 2021).

2.4.2 ECLAT

Algoritma ECLAT (*Equivalence Class Transformation*) merupakan metode *frequent itemset mining* yang menggunakan pendekatan *vertical database format*. Algoritma ini bekerja dengan menyimpan *Transaction ID* (TID) untuk setiap item dan melakukan proses *intersection* antar TID untuk menemukan *frequent itemset*. Kelebihan algoritma ini pada efisiensi proses pencarian itemset karena menggunakan operasi *intersection* yang cepat. Namun, penggunaan memori dapat meningkat ketika jumlah transaksi dan item sangat besar.

2.4.3 FP-Growth

Algoritma FP-Growth (*Frequent Pattern Growth*) merupakan algoritma yang menggunakan struktur data *FP-Tree* untuk menyimpan data transaksi secara terkompresi. Berbeda dengan Apriori, FP-Growth ini tidak membentuk kandidat itemset sehingga mampu mengurangi kompleksitas komputasi dan mempercepat proses mining pada dataset besar (Hegazy et al., 2022). Algoritma ini banyak digunakan dalam penelitian market basket analysis karena mampu menghasilkan *association rule* dengan lebih cepat pada transaction dataset berukuran besar.

2.5 Parameter Evaluasi

Parameter evaluasi yang digunakan dalam penelitian ini atas parameter *association rule* dan parameter performa algoritma.

- *Support* : *Support* digunakan untuk mengukur tingkat kemunculan suatu itemset dalam keseluruhan transaksi.
- *Confidence*: *Confidence* digunakan untuk mengukur tingkat kepercayaan hubungan antara *antecedent* dan *consequent* pada *association rule*.
- *Lift*: *Lift* digunakan untuk mengetahui tingkat kekuatan hubungan antar item dibandingkan dengan kemunculan acak.
- *Execution Time*: *Execution time* digunakan untuk mengukur lama waktu yang dibutuhkan algoritma dalam proses *frequent itemset mining*.
- Jumlah *Frequent Itemset* dan *Association Rule*: Parameter ini digunakan untuk membandingkan kemampuan masing-masing algoritma dalam menghasilkan pola asosiasi dari dataset.

2.6 Pipeline Penelitian


Berikut adalah tahapan pipeline penelitian yang diterapkan secara berurutan menggunakan pendekatan *Knowledge Discovery in Databases* (KDD):

Tabel 2. Pipeline Penelitian

No	Tahap	Keterangan
1	Data Collection	Mengunduh Online Retail Dataset dari Kaggle (541.909 transaksi, 8 atribut)
2	Data Selection	Memilih atribut relevan: InvoiceNo, Description, Quantity, UnitPrice, Country
3	Data Preprocessing	Hapus missing value, transaksi batal (prefix 'C'), Quantity ≤ 0 , data duplikat, normalisasi nama barang
4	Data Transformation	Konversi ke format basket transaction (binary matrix: 1 = dibeli, 0 = tidak dibeli)
5	Frequent Itemset Mining	Jalankan 3 algoritma: Apriori, ECLAT, FP-Growth dengan min_sup = 0.01, 0.02, 0.05
6	Association Rule Mining	Bentuk association rules berdasarkan frequent itemset (parameter: Support, Confidence, Lift)
7	Evaluation & Comparison	Bandingkan execution time, memori, jumlah itemset dan rules antar algoritma
8	Output	Top-10 association rules (lift tertinggi) + Laporan komparatif performa algoritma

Gambar 1. Diagram Pipeline

PIPELINE PENELITIAN



BAB 3 Hasil dan Pembahasan Progres Proyek

3.1 Dataset Penelitian

Dataset berisi data transaksi penjualan sebuah perusahaan retail online yang menjual berbagai produk kebutuhan rumah tangga dan souvenir kepada pelanggan dari berbagai negara. Dataset terdiri dari sekitar 541.909 data transaksi dengan 8 atribut utama yaitu *invoiceNo*, *StockCode*, *description*, *Quantity*, *InvoiceData*, *UnitPrice*, *CustomerID*, dan *Country*. Data transaksi dataset ini dari periode 1 Desember 2010 sampai 9 Desember 2011.

3.2 Preprocessing Data dan EDA

3.2.1 Preprocessing Data

- Filter Negara UK**
Pada tahap ini data transaksi difilter sehingga hanya transaksi dari negara United Kingdom yang digunakan dalam penelitian.
- Menghapus Transaksi Cancel**
Transaksi yang dibatalkan dihapus dari dataset. Data transaksi cancel ditandai dengan nomor invoice yang diawali huruf "C".
- Menghapus Missing Value**
Baris data yang memiliki missing value pada kolom Description dihapus karena nama produk diperlukan dalam proses pembentukan itemset dan association rules.
- Menghapus Quantity dan UnitPrice Tidak Valid**
Data dengan nilai Quantity ≤ 0 dan UnitPrice ≤ 0 dihapus dari dataset karena dianggap tidak merepresentasikan transaksi penjualan yang valid.
- Normalisasi Nama Produk**
Nama produk dibersihkan dengan menghapus spasi berlebih dan merubah seluruh teks menjadi huruf kapital.

f. Menghapus Duplikat

Data duplikat dihapus untuk mencegah redundansi data.


g. Transformasi Feature Tambahan

Beberapa feature tambahan dibuat untuk mendukung proses analisis, yaitu Revenue untuk menghitung total pendapatan transaksi, YearMonth untuk analisis bulanan, DayOfWeek untuk analisis hari transaksi, Hour untuk analisis jam transaksi.

Hasil preprocessing menghasilkan dataset yang lebih bersih, terstruktur, dan siap digunakan pada tahap Exploratory Data Analysis (EDA) dan association rule mining.


3.2.2 Exploratory Data Analysis (EDA)

a. Funnel Preprocessing




Dataset yang awalnya berjumlah 541,909 setelah melewati 6 tahapan preprocessing dan menyisakan 479,985 data yang siap dianalisis.

b. Top Produk Terlaris



Dalam grafik di atas produk yang paling laris yaitu Paper Craft , Litte Birdie sebanyak 80,995 unit, diikuti Medium Ceramic Top Storage Jar sebanyak 77,036 unit, dan World War 2 Gliders Asstd Designs sebanya 49,430 unit. Produk rumah tangga atau dekorasi yang mendominasi penjualan. Selisih jumlah penjualan antara dua produk teratas dengan produk lainnya terlihat cukup jauh, yang berarti produk tersebut memiliki tingkat popularitas yang tinggi di kalangan pelanggan. Banyak produk kategori seperti dekorasi rumah, storage, gift item, dan kitchen accessories yang menduduki top penjualan. Hal ini menunjukkan bahwa pelanggan pada dataset Online Retail cenderung banyak membeli produk dekoratif dan kebutuhan rumah tangga.


c. Tren Revenue dan Transaksi



Pola yang terlihat pada awal tahun yaitu bulan Januari-Februari 2011 penjualan mengalami penurunan dan mulai meningkat lagi pada bulan maret. Lonjakan penjualan besar terjadi pada bulan September, Oktober, dan puncaknya pada bulan November dengan transaksi sekitar 2,500 dan revenue mencapai £1,3 juta. Kenaikan tajam di akhir tahun kemungkinan karena musim belanja, persiapan Natal, atau promo akhir tahun. Pada bulan Desember penjualan turun drastis kemungkinan karena data belum lengkap sampai akhir bulan atau periode observasi berhenti sebelum akhir bulan.

d. Distribusi Quantity dan Harga


Distribusi Variabel Numerik — UK Data Bersih



Berdasarkan grafik diatas terlihat bahwa sebagian besar transaksi memiliki jumlah pembelian (Quantity) rendah dengan median sebesar 3 item. Selain itu, mayoritas produk memiliki harga murah dengan median UnitPrice sebesar £2.10. Distribusi data yang jauh lebih tinggi dibandingkan sebagian besar data lainnya. Hal ini menunjukkan bahwa pelanggan umumnya membeli produk murah dalam jumlah kecil hingga sedang.


e. Pola Hari dan Jam Transaksi

Pola Waktu Pembelian Pelanggan UK



Pada grafik diatas terlihat bahwa hari Kamis memiliki transaksi tertinggi di angka 3807, disusul hari Rabu dan Selasa. Pada hari Minggu transaksi lebih rendah sedangkan hari Sabtu hampir tidak ada transaksi. Aktivitas belanja paling tinggi terjadi pada hari kerja bukan hari libur, kemungkinan pelanggan banyak dari bisnis atau toko dan transaksi dilakukan saat jam kerja. Grafik kedua diatas terlihat bahwa transaksi mulai banyak dilakukan pukul 9-10 pagi, puncaknya pada jam 12 siang, dan setelah jam 4 sore transaksi mulai menurun drastis. Mayoritas transaksi terjadi pada jam kerja dan jam makan siang. Hal ini bisa dimanfaatkan untuk melakukan promosi pada pukul 10-14 kemudian khusus hari Kamis karena di jam tersebut banyak terjadi transaksi.

f. Heatmap Hari x Jam



Hasil heatmap ini mengonfirmasi grafik sebelumnya yaitu pelanggan UK paling aktif saat weekday, jam kerja, terutama pada jam siang. Kemungkinan Transaksi dilakukan saat istirahat kerja atau transaksi dilakukan oleh bisnis/B2B retailer.

3.3 Transformasi Basket Transaction

Setelah data dibersihkan dari nilai yang hilang dan transaksi yang tidak valid, tahap selanjutnya adalah mengubah struktur data agar sesuai dengan format yang dibutuhkan oleh algoritma *Frequent Itemset Mining* (seperti Apriori, FP-Growth, maupun Eclat). Data transaksi awal pada umumnya berbentuk *long format* (memanjang ke bawah), di mana satu struktur pembayaran (InvoiceNo) bisa terdiri dari banyak baris tergantung jumlah barang yang dibeli. Algoritma pencarian pola membutuhkan data dalam bentuk matriks transaksi atau *basket format (wide format)*. Oleh karena itu, dilakukan transformasi dengan tahapan sebagai berikut:

1. Perubahan ke Matriks Basket (*Pivoting*) Data transaksi awal yang memanjang (*long format*) dikelompokkan berdasarkan Invoice dan dibentangkan menjadi kolom-kolom Produk (*wide format*). Setiap baris kini mewakili satu keranjang belanja.
2. Binarisasi (*Boolean Transaction Matrix*) Algoritma asosiasi hanya peduli pada apakah barang dibeli atau tidak, bukan berapa banyak yang dibeli. Oleh karena itu, jumlah barang (kuantitas) diubah menjadi nilai Boolean biner:

Dari proses transformasi ini, dihasilkan sebuah matriks *sparse* (matriks yang didominasi oleh nilai nol/*False*). Berdasarkan *output* program, matriks *basket* ini memiliki dimensi 18019 transaksi baris dan 3996 kolom produk. Tingkat kepadatan data (*density*) berada di angka 0.66%, yang berarti dari total keseluruhan kemungkinan kombinasi barang yang bisa dibeli, hanya sebagian kecil yang benar-benar terisi atau dibeli oleh pelanggan. Rata-rata setiap transaksi berisi sekitar 26.3 jenis barang yang berbeda. Matriks biner inilah yang nantinya akan dimasukkan ke dalam model algoritma untuk dicari pola asosiasinya.

3.4 Implementasi Algoritma

3.4.1 Implementasi Apriori

Algoritma Apriori bekerja secara iteratif dengan pendekatan *bottom-up*. Pada setiap iterasi, algoritma memindai seluruh database transaksi untuk menghitung frekuensi kandidat itemset, kemudian memangkas kandidat yang tidak memenuhi nilai minimum

support. Proses ini diulang dari 1-itemset, 2-itemset, hingga tidak ada lagi kandidat yang memenuhi syarat. Prinsip utama yang digunakan adalah *Apriori property*: jika suatu itemset tidak frequent, maka semua supersetnya juga tidak frequent.

Implementasi menggunakan library `mlxtend.frequent_patterns` dengan fungsi `apriori()`. Parameter yang digunakan adalah `min_support` sebesar 0,01; 0,02; dan 0,05, serta `use_colnames=True` untuk menghasilkan nama produk yang terbaca. Association rule kemudian dibentuk menggunakan fungsi `association_rules()` dengan metrik lift.

Tabel 3. Hasil Frequent Itemset dan Association Rules Apriori

min_support	Frequent Itemset	Association Rules	Waktu Eksekusi	Memori
0,01	2.158	4.382	1,87 detik	8,6 MB
0,02	401	218	0,50 detik	8,5 MB
0,05	34	0	0,17 detik	8,5 MB

Apriori menghasilkan jumlah frequent itemset yang identik dengan dua algoritma lainnya di setiap level support, mengkonfirmasi konsistensi implementasi. Apriori terbukti paling cepat dan paling hemat memori di antara ketiga algoritma pada dataset ini, dengan konsumsi memori yang stabil di sekitar 8,5 MB tanpa bergantung pada nilai minimum support. Pada `min_sup = 0,05`, tidak terbentuk satu pun association rule karena 34 frequent itemset yang dihasilkan tidak ada yang memenuhi threshold confidence untuk pembentukan rule.

3.4.2 Implementasi ECLAT

ECLAT (*Equivalence Class Transformation*) menggunakan pendekatan *vertical database format*, berbeda dengan Apriori yang berbasis horizontal. Setiap item direpresentasikan sebagai daftar Transaction ID (TID-list) yang menyimpan seluruh nomor transaksi di mana item tersebut muncul. Untuk menemukan frequent itemset, ECLAT melakukan operasi *intersection* antar TID-list: dua item dianggap frequent jika irisan TID-list keduanya memiliki jumlah elemen yang memenuhi minimum support. Pendekatan ini menghindari pemindaian ulang seluruh database karena informasi frekuensi sudah tersimpan dalam TID-list.

Implementasi ECLAT dilakukan secara manual menggunakan Python dengan merepresentasikan data ke dalam format vertikal berupa TID-list pada setiap item, kemudian melakukan proses intersection secara rekursif untuk menemukan kombinasi item yang frequent. Parameter minimum support yang digunakan sama seperti algoritma Apriori yaitu 0,01; 0,02; dan 0,05. Setelah proses frequent itemset mining selesai dilakukan hasil itemset kemudian dikonversi ke dalam bentuk *DataFrame* untuk membentuk association rules menggunakan fungsi `association_rules()` dari library `mlxtend`. Dengan pendekatan ini algoritma ECLAT tidak hanya menghasilkan frequent itemset tetapi juga association rules yang dapat dibandingkan secara langsung dengan Apriori dan FP-Growth.

Tabel 4. Hasil Frequent Itemset dan Association Rules ECLAT

min_support	Frequent Itemset	Association Rules	Waktu Eksekusi	Memori
0,01	2.158	4.382	8,90 detik	41,3 MB
0,02	401	218	3,02 detik	18,9 MB
0,05	34	0	2,00 detik	3,1 MB

ECLAT menghasilkan jumlah frequent itemset yang sama dengan Apriori dan FP-Growth di semua level support. Dari sisi waktu eksekusi, ECLAT berada di posisi tengah, lebih lambat dari Apriori namun jauh lebih cepat dari FP-Growth. Yang menarik, konsumsi memori ECLAT sangat berkorelasi dengan nilai min_support: pada min_sup = 0,01 ECLAT mengonsumsi 41,3 MB karena harus menyimpan TID-list untuk ribuan itemset, namun turun drastis ke 3,1 MB pada min_sup = 0,05 karena lebih sedikit itemset yang perlu disimpan. Ini merupakan karakteristik khas representasi vertikal yang sangat sensitif terhadap jumlah itemset yang diproses. Penambahan proses association rule generation pada implementasi ECLAT memungkinkan algoritma ini menghasilkan pola asosiasi produk yang dapat digunakan untuk kebutuhan rekomendasi produk dan strategi cross-selling.

3.4.3 Implementasi FP-Growth

FP-Growth (*Frequent Pattern Growth*) menggunakan struktur data *FP-Tree* untuk menyimpan data transaksi secara terkompresi dalam dua kali pemindaian database. Pemindaian pertama menghitung frekuensi setiap item dan membuang item yang tidak memenuhi minimum support. Pemindaian kedua membangun *FP-Tree* dengan menyusun item dalam setiap transaksi berdasarkan urutan frekuensi menurun, sehingga transaksi yang berbagi prefix yang sama dapat digabungkan dalam satu cabang pohon. Frequent itemset kemudian diekstraksi melalui pembangunan *conditional FP-Tree* secara rekursif tanpa perlu membentuk kandidat itemset, yang menjadi keunggulan utama algoritma ini.

Implementasi menggunakan `mlxtend.frequent_patterns` dengan fungsi `fpgrowth()`. Parameter yang digunakan adalah min_support sebesar 0,01; 0,02; dan 0,05, serta `use_colnames=True`. Association rule selanjutnya dibentuk dari frequent itemset menggunakan fungsi `association_rules()` dengan parameter `metric="lift"`.

Tabel 5. Hasil Frequent Itemset dan Association Rules FP-Growth

min_support	Frequent Itemset	Association Rules	Waktu Eksekusi	Memori
0,01	2.158	4.382	32,32 detik	97,7 MB
0,02	401	218	11,17 detik	48,4 MB
0,05	34	0	2,46 detik	4,9MB

FP-Growth menghasilkan jumlah frequent itemset dan association rule yang identik dengan Apriori, mengkonfirmasi kebenaran implementasi. Namun FP-Growth mencatat waktu eksekusi dan konsumsi memori tertinggi di antara ketiga algoritma pada dataset

ini. Hal ini disebabkan oleh overhead pembangunan struktur FP-Tree yang cukup besar saat jumlah transaksi dan item sangat banyak.

3.5 Komparasi Performa Algoritma

3.5.1 Ringkasan Evaluasi Kinerja

Tabel 6. Output

Parameter	Apriori	ECLAT	FP-Growth	Satuan
Execution Time (min_sup=0.01)	1,87	8,90	32,32	detik
Execution Time (min_sup=0.02)	0,50	3,02	11,17	detik
Execution Time (min_sup=0.05)	0,17	2,00	2,46	detik
Jumlah Frequent Itemset (min_sup=0.01)	2158	2158	2158	itemset
Jumlah Frequent Itemset (min_sup=0.02)	401	401	401	itemset
Jumlah Frequent Itemset (min_sup=0.05)	34	34	34	itemset
Jumlah Association Rule (min_sup=0.01)	4382	4382	4382	rules
Jumlah Association Rule (min_sup=0.02)	218	218	218	rules
Jumlah Association Rule (min_sup=0.05)	0	0	0	rules
Konsumsi Memori (min_sup=0.01)	8,6	41,3	97,7	MB
Konsumsi Memori (min_sup=0.02)	8,5	18,9	48,4	MB
Konsumsi Memori (min_sup=0.05)	8,5	3,1	4,9	MB

Berdasarkan hasil komparasi, algoritma Apriori menunjukkan performa terbaik pada dataset Online Retail UK. Apriori memiliki waktu tercepat dan penggunaan memori yang stabil pada seluruh nilai minimum support yang diuji. Ketiga algoritma menghasilkan jumlah frequent itemset dan association rule yang sama. Oleh karena itu Apriori dinilai paling efisien dan optimal pada dataset penelitian ini.

3.5.2 Analisis Efisiensi Algoritma

Berdasarkan hasil pengujian, algoritma Apriori menunjukkan performa lebih cepat dibandingkan ECLAT dan FP-Growth. Hal ini dipengaruhi oleh karakteristik dataset yang cenderung sparse, yaitu setiap transaksi hanya berisi sedikit item dibandingkan jumlah total produk yang ada. Hal inilah yang menyebabkan jumlah candidate itemset yang terbentuk tidak terlalu besar sehingga Apriori masih dapat bekerja secara efisien. Selain itu, minimum support yang digunakan juga mempengaruhi performa algoritma. Semakin besar nilai minimum support maka semakin sedikit itemset yang memenuhi syarat frequent sehingga waktu eksekusi dan penggunaan memori pada semua algoritma menjadi lebih rendah. Sebaliknya, nilai minimum support yang kecil menghasilkan lebih banyak kombinasi itemset sehingga proses mining menjadi lebih kompleks.

Meskipun secara teori FP-Growth umumnya lebih efisien pada dataset besar dan kompleks namun pada penelitian ini Apriori memberikan performa yang terbaik. Hal ini disebabkan dataset Online Retail memiliki tingkat sparsity yang tinggi dengan rata-rata jumlah item per transaksi relatif kecil sehingga struktur FP-Tree pada FP-Growth tidak terbentuk secara optimal dan menyebabkan penggunaan memori menjadi lebih besar dibandingkan Apriori.

3.6 Output Pola Pembelian dan Implikasi Rekomendasi Produk

3.6.1 Output Pola Pembelian

Association rules final pada penelitian ini menggunakan hasil algoritma Apriori dengan minimum support 0,02. Pemilihan nilai minimum support berdasarkan pada keseimbangan antara jumlah frequent itemset, jumlah association rules, serta kemudahan interpretasi pola yang dihasilkan. Pada minimum support 0,02 diperoleh 401 frequent itemset dan 218 association rules yang masih cukup representatif untuk dianalisis lebih lanjut. Selain itu, algoritma Apriori dipilih karena menghasilkan waktu eksekusi dan konsumsi memori paling efisien dibandingkan ECLAT dan FP-Growth pada dataset yang bersifat sparse.

Tabel 7. Top-10 Association Rules

No.	Antecedent	Consequent	Support	Confidence	Lift
1	WOODEN STAR CHRISTMAS SCANDINAVIAN	WOODEN HEART CHRISTMAS SCANDINAVIAN	0,0204	76,8%	27,197
2	WOODEN HEART CHRISTMAS SCANDINAVIAN	WOODEN STAR CHRISTMAS SCANDINAVIAN	0,0204	72,3%	27,197
3	PINK REGENCY TEACUP AND SAUCER	ROSES REGENCY TEACUP AND SAUCER + GREEN REGENCY TEACUP AND SAUCER	0,0273	70,1%	18,041
4	ROSES REGENCY TEACUP AND SAUCER + GREEN	PINK REGENCY TEACUP AND SAUCER	0,0273	70,3%	18,041

	REGENCY TEACUP AND SAUCER				
5	ROSES REGENCY TEACUP AND SAUCER + PINK REGENCY TEACUP AND SAUCER	GREEN REGENCY TEACUP AND SAUCER	0,0273	90,3%	17,453
6	GREEN REGENCY TEACUP AND SAUCER	ROSES REGENCY TEACUP AND SAUCER + PINK REGENCY TEACUP AND SAUCER	0,0273	52,8%	17,453
7	GREEN REGENCY TEACUP AND SAUCER + PINK REGENCY TEACUP AND SAUCER	ROSES REGENCY TEACUP AND SAUCER	0,0273	85,4%	16,099
8	ROSES REGENCY TEACUP AND SAUCER	GREEN REGENCY TEACUP AND SAUCER + PINK REGENCY TEACUP AND SAUCER	0,0273	51,5%	16,099
9	PINK REGENCY TEACUP AND SAUCER	GREEN REGENCY TEACUP AND SAUCER	0,0320	82,1%	15,863
10	GREEN REGENCY TEACUP AND SAUCER	PINK REGENCY TEACUP AND SAUCER	0,0320	61,8%	15,863

Dari Top-10 association rules, teridentifikasi dua kelompok pola pembelian yang sangat kuat:

- Kelompok 1 — Dekorasi Natal Skandinavia (Rules #1 dan #2)
WOODEN STAR CHRISTMAS SCANDINAVIAN dan *WOODEN HEART CHRISTMAS SCANDINAVIAN* menunjukkan keterkaitan pembelian tertinggi di antara seluruh produk dengan lift = 27,164 — artinya kemungkinan kedua produk dibeli bersama adalah 27 kali lebih besar dibandingkan jika pembeliannya bersifat independen. Confidence sebesar 72,3%–76,8% berarti lebih dari 7 dari 10 pelanggan yang membeli salah satu item pasti membeli yang lain. Nilai support 0,0204 menunjukkan pasangan ini muncul di sekitar 2% dari seluruh transaksi UK, yang terbilang signifikan mengingat banyaknya ragam produk dalam dataset.
- Kelompok 2 — Koleksi Regency Teacup and Saucer (Rules #3–#10)

Tiga varian *Regency Teacup and Saucer* (Roses, Green, dan Pink) membentuk pola pembelian yang saling terhubung satu sama lain dalam berbagai kombinasi 2-item dan 3-item. Rule paling kuat dalam kelompok ini adalah rule #5: pelanggan yang sudah membeli *Roses* dan *Pink* memiliki probabilitas 90,3% untuk turut membeli *Green*. Selain itu, beberapa rule lain juga menunjukkan nilai confidence di atas 80% yang menunjukkan ketiga produk tersebut dibeli secara bersamaan sebagai satu set koleksi. Nilai lift yang seluruhnya berada di atas 15 menunjukkan hubungan asosiasi yang sangat kuat antarproduk *Regency Teacup and Saucer* sehingga berpotensi dimanfaatkan untuk strategi cross-selling dan product bundling.

3.6.2 Implikasi Rekomendasi Produk

1. Product Bundling

Berdasarkan pola di atas, dua paket bundling berikut sangat direkomendasikan:

- "Scandinavian Christmas Decor Set": Paket berisi *Wooden Heart + Wooden Star Christmas Scandinavian*, ditawarkan dengan harga bundel yang sedikit lebih hemat dibanding pembelian satuan. Didukung oleh lift 27,19 yang sangat tinggi.
- "Complete Regency Tea Set": Paket berisi ketiga varian *Regency Teacup and Saucer* (Roses + Green + Pink) sekaligus. Didukung oleh confidence 3-item rules yang mencapai 85–90%.

2. Cross-Selling melalui Rekomendasi Otomatis

Sistem rekomendasi pada halaman produk dan keranjang belanja dapat dikonfigurasi berdasarkan rules ini:

- Saat pelanggan membuka atau menambahkan *Green Regency Teacup* ke keranjang → sistem otomatis merekomendasikan varian *Roses* dan *Pink*.
- Saat pelanggan membeli *Wooden Heart Christmas Scandinavian* → sistem menampilkan *Wooden Star Christmas Scandinavian* sebagai "Produk yang Sering Dibeli Bersama".

3. Penempatan Produk (Product Placement)

Dalam tampilan toko digital, ketiga varian *Regency Teacup* sebaiknya ditampilkan dalam satu halaman koleksi atau kategori yang sama agar pelanggan mudah menemukan dan memilih ketiganya sekaligus. Produk dekorasi Natal Skandinavia juga sebaiknya ditempatkan berdekatan dalam kategori musiman.

4. Promosi Musiman

Kedua produk dekorasi Natal Skandinavia sangat cocok untuk kampanye promosi tematik menjelang musim Natal dengan pesan seperti "*Lengkapi koleksi dekorasi Skandinaviamu*", memanfaatkan kecenderungan pelanggan yang memang cenderung membeli keduanya sekaligus.

BAB 4 Kesimpulan dan Saran

Berdasarkan hasil penelitian, teknik Association Rule Mining berhasil diimplementasikan pada dataset Online Retail melalui tahapan preprocessing data, transformasi basket transaction, pencarian frequent itemset, dan pembentukan association rules menggunakan algoritma Apriori, ECLAT, dan FP-Growth. Proses mining berhasil menemukan pola asosiasi antar produk dari 18.091 transaksi dan 3.996 produk dengan karakteristik dataset yang bersifat sparse. Hasil pengujian menunjukkan bahwa

nilai minimum support mempengaruhi jumlah frequent itemset, association rules, waktu eksekusi, dan penggunaan memori pada seluruh algoritma.

Association rules yang dihasilkan menunjukkan adanya pola pembelian produk yang kuat dan berpotensi digunakan untuk strategi cross-selling. Produk WOODEN STAR CHRISTMAS SCANDINAVIAN dan WOODEN HEART CHRISTMAS SCANDINAVIAN memiliki hubungan asosiasi tertinggi dengan nilai lift mencapai 27,197. Selain itu, kombinasi produk Regency Teacup and Saucer juga menunjukkan nilai confidence hingga 90,3% yang menunjukkan pelanggan cenderung membeli beberapa varian produk secara bersamaan sebagai satu set koleksi. Pola tersebut dapat dimanfaatkan untuk produk bundling, rekomendasi otomatis, penempatan produk, dan promos musiman pada bisnis ritel.

Hasil komparasi menunjukkan bahwa algoritma Apriori memiliki tingkat efisiensi terbaik dibandingkan FP-Growth dan ECLAT berdasarkan parameter waktu eksekusi dan penggunaan memori. Pada minimum support 0,02, Apriori menghasilkan 401 frequent itemset dan 218 association rules dengan waktu eksekusi 0,50 detik dan penggunaan memori sebesar 8,5 MB. karakteristik dataset yang sparse menyebabkan jumlah candidate itemset tidak terlalu besar sehingga Apriori tetap mampu bekerja secara efisien dan bahkan dapat unggul dari FP-Growth dan ECLAT pada penelitian ini.

Penelitian selanjutnya dapat menggunakan dataset dengan ukuran yang lebih besar atau karakteristik transaksi yang lebih kompleks untuk melihat performa algoritma pada kondisi data yang berbeda. Dari sisi implementasi bisnis, hasil association rules dapat dikembangkan menjadi sistem rekomendasi produk otomatis pada e-commerce sehingga pelanggan dapat memperoleh rekomendasi produk terkait secara langsung berdasarkan pola pembelian pelanggan sebelumnya.

Daftar Pustaka

- Chen, Y., & Li, Z. (2022). Efficient frequent itemset mining using vertical data representation and intersection operations. *Journal of Data Engineering*, 15(3), 112–128. <https://doi.org/10.1016/j.jde.2022.03.005>
- Hegazy, M., Hassan, M., & Abo-Elsoud, M. (2022). An enhanced FP-Growth algorithm for mining frequent patterns in large-scale transaction databases. *IEEE Access*, 10, 45231–45244. <https://doi.org/10.1109/ACCESS.2022.3169874>
- Pratama, A. R., Wijaya, D. R., & Santoso, H. B. (2023). Komparasi algoritma Apriori dan FP-Growth dalam analisis market basket pada data transaksi e-commerce. *Jurnal Ilmu Komputer dan Informasi*, 16(1), 55–67. <https://doi.org/10.21609/jiki.v16i1.1087>
- Rahman, S., & Kumar, A. (2024). FP-Growth vs. Apriori: A comprehensive benchmark on retail transaction datasets. *Expert Systems with Applications*, 238, 121845. <https://doi.org/10.1016/j.eswa.2023.121845>
- Tunguz, B. (2020). Online Retail Dataset [Data set]. Kaggle. <https://www.kaggle.com/datasets/tunguz/online-retail>
- Wardani, N. W. (2021). Implementasi algoritma Apriori untuk rekomendasi produk pada sistem e-commerce. *Jurnal Teknologi Informasi dan Ilmu Komputer (JTIIK)*, 8(4),



771–780. <https://doi.org/10.25126/jtiik.2021842791>

Xie, Q. (2021). Research on association rule mining algorithm and its application in retail business analysis. Journal of Physics: Conference Series, 1757(1), 012023. <https://doi.org/10.1088/1742-6596/1757/1/012023>

Kontribusi Anggota Kelompok

No	Nama / NIM	Kontribusi Final
1	Ananda Keissa Az Zahra / 24031554051	Penulisan abstrak dan kesimpulan; revisi preprocessing
2	Laili Nurrohmatul Fadhila Z. / 24031554093	Penulisan bab 3 frequent itemset mining; revisi kode algoritma ECLAT
3	Eka Putri Maharani / 24031554121	Penulisan bab 3 output pola pembelian dan evaluasi; revisi kode EDA